[파리 시장 진출을 위한 한국형 저가 커피 현지화 및 입지 최적화 시뮬레이션]

[휘낭시에]

[강나윤 – 남하린 – 이예지 – 제이드]

Submitted: [2026-10-19]

Team

Member	Student ID	Main role	What they own
강나윤	2210971	[data / modeling]	[K-Means location clustering, LDA review topic modeling (baseline)]
남하린	2214182	[modeling / Visualization]	[Monte Carlo BEP simulation, Folium map visualization]
이예지	2114926	[evaluation / writing]	[error analysis, final report & presentation]
Zayd	2670136	[data / modeling]	[dataset collection, preprocessing (Paris commercial data & French reviews)]

Problem definition

What problem are you solving?

Problem : 한국형 저가, 고회전 커피 모델이 파리 시장에 진출할 때, 높은 임대료와 현지 소비자 성향을 극복하고 수익성을 확보할 수 있는 최적의 입지와 현지화 전략을 도출하는 것.
Input : 파리 로컬 및 글로벌 카페의 프랑스어 리뷰 데이터, 파리 20개 구의 공공데이터(평균 임대료, 인구 통계, 기존 카페 밀집도), 한국 저가 커피 원가 데이터
Prediction(Output) : 1. 현지 소비자가 중시하는 카페 경험 핵심 키워드 / 2. 임대료 대비 잠재 고객이 높은 최적의 타겟 상권 / 3. 해당 타겟 상권에서의 월간 손익분기점 달성 확률 및 예상 수익 분포

What decision does this model support?

의사결정 : 파리 진출 시 '어느 구에 1호점을 오픈할 것인지', 그리고 1.5유로 가격을 유지하기 위해 '어떤 형태와 마케팅 포인트를 가져갈 것인지'에 대한 전략적 결정을 지원함.
행동의 변화 : 단순한 직관이나 유동인구가 가장 많은 비싼 핵심 상권에 무작정 진출하는 대신, 알고리즘이 추천한 가성비 상권에 현지 맞춤형으로 진출하여 초기 투자 실패 위험을 줄임.

Who is the user?

사용자 : 메*커피, 컴**커피 등 유럽 시장 진출을 기획하는 한국 저가 커피 프랜차이즈의 사업 기획자, 해외 진출 전략팀, 마스터 프랜차이즈 투자자
사용 상황 : 파리 1호점 입점 후보지를 검토하고, 이사회나 투자자에게 '왜 이 위치에, 이런 형태로 진출해야 수익이 나는가'를 데이터 기반으로 설득하는 기획 및 피칭 단계

Background and related work

Why this problem matters

규모와 비용 : 한국 저가커피 브랜드들은 국내 시장 포화로 인해 해외 진출이 필수적인 상황이다. 하지만 파리 중심부의 상업용 임대료는 면적 당 월 수십 ~ 수백 유로에 달할 정도로 매우 높기 때문에 실패 시 매몰 비용의 규모가 큼.
빈도 : 1.5유로라는 초저가 모델을 유지하려면 회전율이 중요하다. 단순한 직관만으로 임대료가 비싼 핵심 상권에 입점했다가 목표 판매 빈도를 못 채우면 즉각적인 적자로 이어지므로, 정교한 입지 선정과 확률적 수익성 검증이 필수적이다.

Existing approach	What they do	Limitation you will address	Source
상용 GIS 상권 분석 솔루션	유동인구와 배후세대를 기반으로 거시적인 우수 상권 및 입지 추천	파리 로컬 특성상 임대료 대비 잠재 고객이 높은 가성비 상권을 미시적으로 찾아내지 못함	ESRI Business Analyst, Geoconcept 등 유럽 상권 분석 플랫폼 웹사이트
전통적 정적 손익분기점 분석 방법론	평균 예상 유동인구와 고정 비용을 바탕으로 단일한 손익분기점 매출을 계산	날씨, 요일, 시즌별 방문율 등 현실 상권의 불확실성을 반영한 확률적 수익 달성 리스크를 예측하지 못함.	경제학원론 교재
외식업 리뷰 대상 단순 감성 분석	식당이나 카페의 리뷰 텍스트를 바탕으로 전체적인 긍정/부정 비율만 산출	1.5유로 초저가 모델이 어필해야 하는 구체적인 핵심 포인트가 무엇인지 숨겨진 주제를 파악하지 못함.	식당 리뷰 분석 관련 대표적인 텍스트 마이닝 논문 'Sentiment Analysis of Restaurant Reviews on TripAdvisor'

Data 1 – 파리 현지 카페 프랑스어 리뷰 데이터

Item	Your answer
Source and license	Google Maps Places API, Tripadvisor 크롤링
Size	약 7000 건의 리뷰 텍스트 : 리뷰 7000행 * 별점, 텍스트 작성일 등 3-4개의 열
Target definition	본 분석은 비지도 학습이므로 명확한 사전 Label은 없음. 단, 감성 분석 시 사전 학습된 모델이 도출하는 긍정/부정 클래스를 파생 변수로 사용
Label distribution	일반적으로 카페 리뷰는 긍정이 70% 이상으로 데이터 쏠림이 있을 것으로 예상됨
Missing / noisy data	별점만 있고 텍스트가 없는 빈 리뷰, 프랑스어가 아닌 타 언어 리뷰, 의미 없는 특수 문자나 단답형 노이즈 데이터
Group or time structure	리뷰 작성 시간 순으로 최신 트렌드 가중치 부여 가능

Do you already have the data in hand?

[ ] Yes, downloaded and opened [•] Partly [ ] Not yet – plan and fallback: [ ]

Data 2 – 파리 구역별 상권 공공데이터 (입지 클러스터링용)

Item	Your answer
Source and license	Paris Open Data 포털, INSEE(프랑스 통계청) 오픈 데이터
Size	20개 구역 * 약 5~10개 열(임대료, 유동인구, 2030비율, 카페 밀집도 등)
Target definition	비지도 학습인 K-Means 클러스터링을 수행하므로 정답 Label은 없음. 알고리즘이 할당하는 클러스터 ID가 최종 타겟 역할
Label distribution	20개 데이터를 3~4개의 군집으로 나누므로, 각 군집당 4~7개의 구역이 고르게 분포할 것으로 예상
Missing / noisy data	특정 구역의 상업용 임대료 통계가 누락되어 있을 수 있지만 이를 평균값으로 대치 예정
Group or time structure	시계열이 아닌 가장 최근 연도 기준 단일 시점 데이터

Do you already have the data in hand?

[ ] Yes, downloaded and opened [●] Partly [ ] Not yet – plan and fallback: [ ]

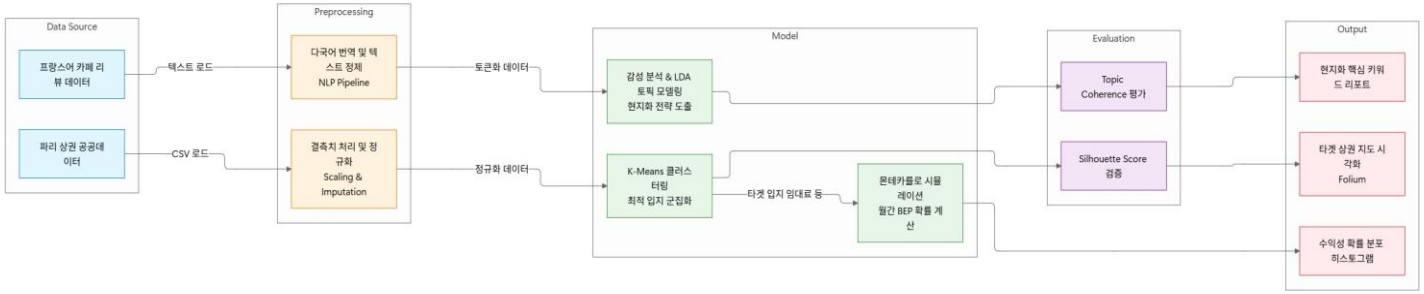
Requirements: functional

ID	Requirement	Priority	How it will be verified
FR-1	시스템은 LDA 토픽 모델링을 통해 프랑스어 카페 리뷰에서 3~5개의 핵심 현지화 토픽을 추출	must	pyLDAvis 시각화 결과물 및 토픽별 주요 키워드 리스트 출력 확인
FR-2	시스템은 임대료, 유동인구, 카페 밀집도를 기준으로 파리의 20개 구를 3~4개의 그룹으로 군집화	must	K-Means 군집 할당 결과 데이터프레임 및 Folium 라이브러리를 활용한 파리 지도 위 군집 시각화
FR-3	시스템은 1.5유로 커피 모델의 월간 손익분기점 달성 확률을 계산	must	10,000회 몬테카를로 시뮬레이션 코드 실행 및 수익 분포를 나타내는 히스토그램 출력
FR-4	시스템은 결측치를 처리하고 수치형 변수를 정규화하여 원시 데이터를 전처리	should	결측치 0개, 평균 0/표준편차 1로 정규화된 최종 데이터프레임 구조 확인
FR-5	시스템은 리뷰 텍스트를 긍정 또는 부정으로 분류하는 감성 분석을 수행	should	각 리뷰 행마다 감성 점수가 추가된 데이터프레임 출력

Requirements: non-functional and constraints

ID	Requirement or constraint	Target value	How it will be checked
NFR-1	Model quality	K-Means 클러스터링의 silhouette score 〉= 0.4 달성 (군집이 얼마나 잘 분리되었는지 평가)	Scikit-learn의 silhouette_score 함수 출력값 확인
NFR-2	Latency or throughput	10,000번의 몬테카를로 시뮬레이션 연산이 10초 이내에 완료될 것	Python time 모듈을 이용한 실행 시간 측정 스크립트
NFR-3	Compute / budget limit	Google Colab free tier	Colab 무료 환경 세션에서 에러 없이 처음부터 끝까지 구동되는지 확인
NFR-4	Data protection / ethics	리뷰 데이터 내 개인 식별 정보 제거	전처리된 최종 데이터셋 컬럼 목록에 개인 식별 정보 관련 열이 존재하지 않는지 육안 확인 및 정규식 마스킹
NFR-5	Schedule constraint	11주차 이내에 전처리 및 분석 베이스라인 모델 구동 완료	11주차 팀 미팅 시 구동 가능한 통합 및 주피터 노트북 파일 리뷰

Preliminary design: system architecture



Block	Tool / library
Data	Pandas, requests : 파리 구역별 통계 CSV 로드 및 Google Places 리뷰 데이터 수집
Preprocessing	Scikit-learn, nltk, googletrans : 상권 수치형 변수 정규화, 리뷰 텍스트 번역 및 이상데이터 제거
Model	Scikit-learn(K-Means), gensim(LDA), numpy(Monte Carlo) : 최적 상권 군집화, 핵심 불만/만족 토픽 추출, 난수 기반 영업 이익 시뮬레이션
Evaluation	Scikit-learn.metrics : Elbow 기법 및 실루엣 계수로 최적의 K 검증
Output / UI	Matplotlib, seaborn, folium : 파리 지도 위 타겟 상권 시각화 및 수익성 확률 분포 히스토그램 출력

Preliminary design: model and data flow

Candidate	Why this one	Risk / cost
[Baseline – required] 룰 기반 필터링 및 단순 정적 손익분기점	코딩이 거의 필요 없고 직관적인 엑셀 계산으로 빠르게 결과를 낼 수 있음	상권 변수 간의 복잡한 관계를 무시하며, 현실의 영업 불확실성을 전혀 반영하지 못해 신뢰도가 낮음
[Model A] K-Means 클러스터링 + LDA 토픽 모델링 + 몬테카를로 시뮬레이션	다차원 데이터를 객관적으로 묶어주고, 텍스트의 숨은 의도를 파악하며, 확률적 리스크를 계산할 수 있어 최적의 가성비와 분석 깊이를 제공함.	클러스터 개수나 토픽 개수를 정할 때 분석가의 주관이 개입될 수 있으며, 초기 하이퍼파라미터 튜닝에 시간 소요
[Model B] 딥러닝 및 강화학습 기반 상권 분석	가장 높은 예측 정확도와 복잡한 비선형 관계를 모델링할 수 있음	짧은 프로젝트 기간 내에 구현하기 불가능에 가까우며, 데이터 양이 딥러닝을 돌리기에는 부족하여 과적합 발생 확률이 높음.

Input features

상권 변수 : 구역별 평균 상업 임대료, 일일 유동인구, 2030세대 비율, 기존 카페 수, 지하철역 개수
리뷰 변수 : 작성일자, 별점, 리뷰텍스트 원문
재무 변수 (시뮬레이션 용) : 예상 커피 단가 1.5유로 설정, 원두 및 부자재 원가, 일평균 예상 판매량(난수 분포 설정용)

Preprocessing steps

Imputation (결측치 대치) : 상권 데이터 중 비어있는 임대료 정보는 인접 구역 평균값으로 채움
Scaling (스케일링) : 단위가 서로 다른 상권 변수를 평균 0, 표준편차 1로 맞춤
NLP Pipeline (자연어 전처리) : 리뷰 텍스트 소문자화, 특수문자 제거, 이상데이터 처리 및 토큰화 진행

Evaluation plan

Item	Plan
Primary metric	Plan : Silhouette Score Reason : 본 프로젝트의 핵심인 상권 입지 분석은 정답 라벨이 없는 비지도 학습이므로, 알고리즘이 파리 20개 구를 얼마나 의미있게 잘 나누었는지 평가할 수 있는 가장 객관적인 수치 지표이다.
Secondary metrics	Plan : Topic Coherence Score, 월간 BEP 달성 확률 Reason : 실루엣 점수만으로는 텍스트 분석 결과의 퀄리티나 최종 목표인 '수익성'을 알 수 없으므로 보조 지표로 활용한다.
Split	Plan : No traditional train/test split (전통적 분할 생략) Reason : 예측 모델이 아닌 탐색적 비지도 학습(Clustering, Topic Modeling)이 주 목적이므로 보유한 데이터를 100% 활용해 인사이트를 도출한다.
Baseline	Plan : Random cluster assignment (무작위 상권 할당) 및 단일 평균값을 이용한 정적 손익분기점 계산 결과 Reason : 우리의 K-Means와 몬테카를로 시뮬레이션이 단순 직관이나 평균값 계산보다 얼마다 우수한지 비교하기 위함이다.
Uncertainty	Plan : Fixed random seeds Reason : K-Means의 초기 중심점 할당이나 10,000번의 몬테카를로 난수 발생 시, 누가 코드를 돌리든 항상 동일한 결과가 나오도록 재현성을 보장한다.

Schedule and risks

Week	Milestone	Owner	Done when
[W1-2]	파리 상권 공공데이터 수집 및 전처리 완료, 프랑스어 리뷰 데이터 확보 및 정제	Zayd	결측치가 제거되고 정규화된 상권 CSV 파일 및 정제된 리뷰 데이터 프레임이 완성되었을 때
[W3-4]	K-Means 입지 군집화 모델 구동 및 LDA 리뷰 토픽 추출 완료 (분석 베이스라인 완성)	강나윤	실루엣 점수가 산출되고 리뷰의 핵심 토픽 3~4개가 시각화 자료로 도출되었을 때
[W5-6]	타겟 상권 대상 몬테카를로 BEP 시뮬레이션 Folium 지도 시각화 완성	남하린	10,000회 시뮬레이션 결과에 따른 수익 달성 확률 히스토그램과 최종 파리 입점 타겟 지도가 도출되었을 때
[W7-8]	분석 결과 종합, 에러 분석, 최종 리포트 및 발표 PPT 작성, 연습	이예지	스토리보드 완성 및 발표 연습이 완료되었을 때

Risk	What you will do instead
프랑스 공공데이터 포털에서 특정 구역의 상업용 임대료 데이터가 누락되어 있을 경우	인접한 구역의 평균 임대료로 결측치를 대치하거나 주거용 부동산 가격 지수를 가중치로 활용하여 임대로 추정하기
다국어 자연어 처리 모델의 한계로 프랑스어 특유의 리뷰 뉘앙스나 은어 파악이 어려운 경우	알고리즘이 뽑아낸 상위 100~200개 핵심 키워드를 직접 검수하고 수동 태깅하여 모델의 한계를 보완하기